UNIVERSITAS MIKROSKIL | Fakultas INFORMATIKA

Unsupervised Learning and Dimensionality Reduction

IF2116 - Pembelajaran Mesin

Pertemuan 6



Sarjana Strata 1

Teknik Informatika

Materi Pertemuan 5

- **a** Konsep Unsupervised Learning
- **b** K-Means Clustering
- **c** Memilih K & Evaluasi Cluster
- **d** Hierarchical, DBSCAN & Perbandingan
- **e** Curse of Dimensionality
- **f** PCA: Intuisi & Matematika
- **g** PCA pada Data Nyata
- **h** t-SNE, UMAP & Praktik Terbaik

Bekal dari Pertemuan sebelumnya

Supervised learning (data berlabel), regularisasi, metrik evaluasi, serta Pipeline dan validasi tanpa leakage. Hari ini kita bekerja **tanpa label**: mencari struktur tersembunyi dan menyederhanakan data.

Tujuan Utama Pembelajaran

- Membedakan **supervised** dan **unsupervised learning**, serta menyebutkan tugas utama unsupervised: *clustering, dimensionality reduction, anomaly detection*.
- Menjelaskan cara kerja **K-Means**, **Hierarchical Clustering**, dan **DBSCAN**, memilih jumlah cluster dengan *Elbow* dan *Silhouette*, serta mengetahui kapan tiap algoritma gagal.
- Menjelaskan **curse of dimensionality** dan menerapkan **PCA**: standarisasi, explained variance, memilih jumlah komponen, dan merekonstruksi data.
- Memakai **t-SNE/UMAP** secara bertanggung jawab untuk visualisasi, serta menggabungkan PCA dan clustering di dalam *Pipeline* yang bebas leakage.

Mampu **menemukan struktur** dalam data tanpa label dan **menyederhanakan** data berdimensi tinggi secara **ilmiah dan dapat dipertanggungjawabkan**.

UNIVERSITAS MIKROSKIL

Dari Data Berlabel ke Data Tanpa Label

1 Clustering

Apakah ada kelompok alami di data?

Kelompokkan sampel yang mirip. Contoh: segmentasi pelanggan, pengelompokan dokumen.

2 Dimensionality Reduction

Bisakah fitur diringkas tanpa kehilangan banyak informasi?

Ubah ratusan fitur menjadi beberapa komponen. Contoh: visualisasi, kompresi, pra-pemrosesan.

3 Interpretasi & Validasi

Apakah hasilnya bermakna?

Tidak ada label untuk dicek. Perlu metrik internal, profil cluster, dan penilaian pakar.

Benang merah: pada supervised learning label memberi tahu model apa yang benar. Pada unsupervised learning, **bentuk data itu sendiri** yang berbicara, sehingga **preprocessing (scaling) dan interpretasi** jauh lebih menentukan.

Unsupervised Learning & Clustering

Konsep • K-Means • Memilih K • Hierarchical • DBSCAN

UNIVERSITAS MIKROSKIL

a **KONSEP UNSUPERVISED LEARNING**

Belajar Tanpa Guru

Data hanya berisi fitur x; tidak ada label y yang "benar".

> *"In unsupervised learning, as you might guess, the training data is unlabeled. The system tries to learn without a teacher."*
>
> — A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow

Aspek	Supervised	Unsupervised
Data latih	(x, y) berlabel	hanya x
Tujuan	Memprediksi y	Menemukan struktur / pola
Evaluasi	Bandingkan dengan label	Metrik internal + interpretasi
Contoh	Regresi, klasifikasi	Clustering, reduksi dimensi

Analogi: Perpustakaan Tanpa Katalog

Ribuan buku menumpuk tanpa label kategori. Kita menyusunnya berdasarkan **kemiripan** (isi, ukuran, topik) lalu **memberi nama** tiap rak. Nama rak adalah interpretasi kita, bukan jawaban dari data.

Empat Tugas Utama Unsupervised Learning

Fokus hari ini: clustering dan dimensionality reduction.

Clustering fokus

Mengelompokkan sampel yang mirip.

Contoh: Segmentasi pelanggan, pengelompokan gen, kompresi gambar.

Dimensionality Reduction fokus

Meringkas banyak fitur menjadi sedikit.

Contoh: Visualisasi 2D, kompresi, pembersihan noise.

Anomaly Detection

Menemukan sampel yang tidak biasa.

Contoh: Fraud, kerusakan mesin, intrusi jaringan.

Association Rules

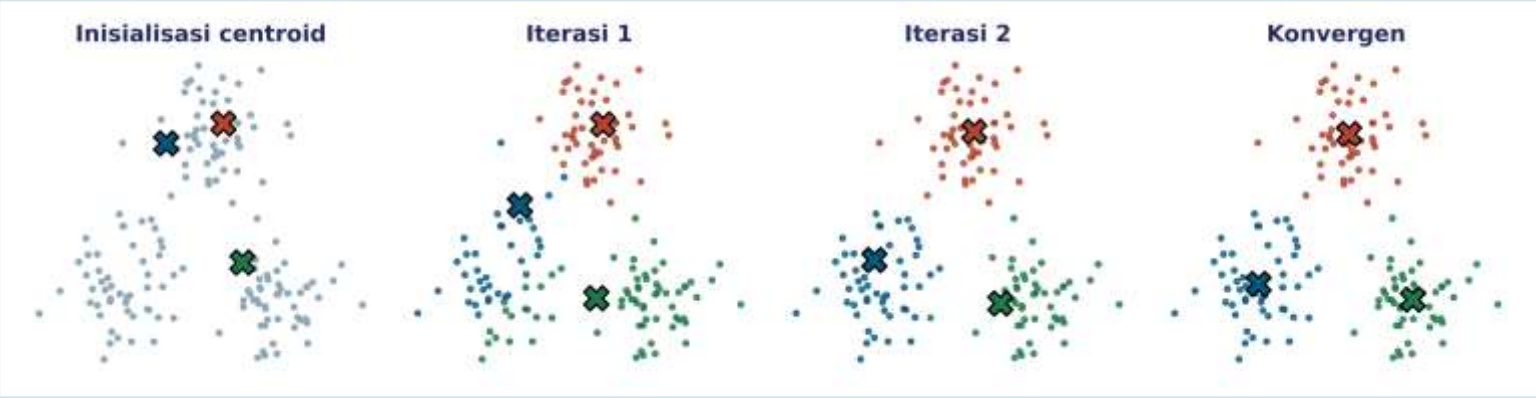
Menemukan item yang sering muncul bersama.

Contoh: Analisis keranjang belanja, rekomendasi.

b **K-MEANS CLUSTERING**

K-Means: Dua Langkah yang Diulang

Bagi data menjadi K cluster berbentuk "bola" dengan pusat (centroid) masing-masing.



1. **Inisialisasi**
   Pilih K centroid awal (disarankan k-means++).
2. **Assignment**
   Tiap titik masuk ke centroid terdekat.
3. **Update**
   Centroid = rata-rata anggota cluster.
4. **Ulangi**
   Sampai assignment tidak berubah.

Tujuan (inertia): $J = \Sigma_k \Sigma_{x \in C_k} \|x - \mu_k\|^2$

Catatan: setiap iterasi pasti menurunkan (atau mempertahankan) J, tetapi hanya menjamin **minimum lokal**. Hasil bergantung pada inisialisasi.

Hitung Manual: K-Means 1 Dimensi

Data: 1, 2, 3, 10, 11, 12 dengan K = 2 dan centroid awal 1 dan 2.

Iterasi	Centroid (A, B)	Anggota A	Anggota B	Centroid baru
1	1 ; 2	{1}	{2, 3, 10, 11, 12}	1 ; 7,6
2	1 ; 7,6	{1, 2, 3}	{10, 11, 12}	2 ; 11
3	2 ; 11	{1, 2, 3}	{10, 11, 12}	2 ; 11 (tetap)

4

J akhir = (1+0+1) + (1+0+1)

Perhatikan iterasi 1: titik 2 sempat masuk cluster B karena centroid awal B = 2. Cluster belum "benar", tetapi setelah centroid diperbarui ke 7,6 assignment membaik pada iterasi 2.

Cek sendiri: jika centroid awal 1 dan 3, apakah hasil akhirnya sama? Coba hitung dan diskusikan.

K-Means Sangat Peka terhadap Skala Fitur

Notebook Pertemuan 5 – Wine (178 sampel, 13 fitur, 3 kelas)

```
X, y = load_wine(return_X_y=True)      # 178 x 13

km_raw = KMeans(3, n_init=10, random_state=42).fit(X)
Xs = StandardScaler().fit_transform(X)
km_std = KMeans(3, n_init=10, random_state=42).fit(Xs)

# ARI vs kelas asli (label TIDAK dipakai saat training)
# raw    : 0.371      standardized : 0.897
```

0.371

ARI tanpa scaling

0.897

ARI setelah StandardScaler

Penyebab: fitur proline bervarians ≈ 98.610, sedangkan alcalinity_of_ash ≈ 11. Jarak Euclidean "didikte" proline.

Jebakan silhouette: silhouette tanpa scaling justru **lebih tinggi** (0,571 vs 0,285), padahal clusternya jauh lebih buruk menurut label. Silhouette dihitung di ruang fitur masing-masing sehingga **tidak dapat dibandingkan lintas preprocessing**. Selalu standarisasi sebelum K-Means, dan nilai hasil dengan beberapa cara.

Inisialisasi: Random vs k-means++

Inisialisasi (n_init = 1)	Inertia rata-rata	Simpangan baku	Terburuk	Iterasi rata-rata
random	1.188.001	21.798	1.240.658	21.4
k-means++	1.178.450	15.842	1.218.629	20.8

Digits (1.797 sampel, 64 fitur), K = 10, 30 seed berbeda. Makin kecil inertia makin baik.

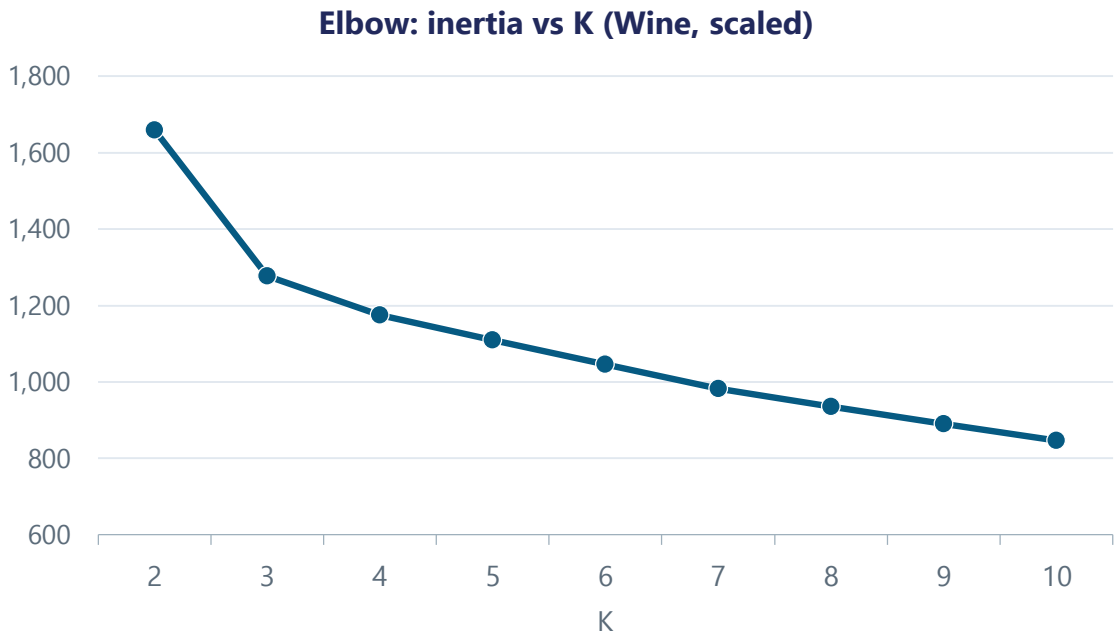
↓ 27%

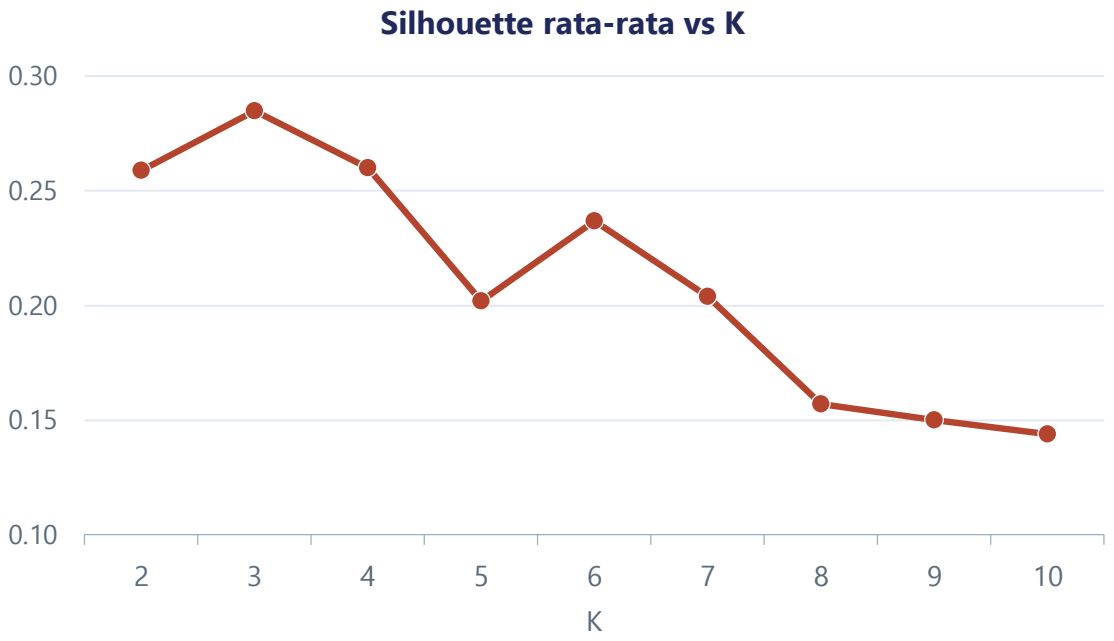
simpangan baku inertia dengan k-means++
(21.798 → 15.843)

- **k-means++** memilih centroid awal yang saling berjauhan, sehingga hasil lebih stabil dan kasus terburuk lebih baik.
- Perbaikannya tidak dramatis; keduanya tetap dapat terjebak minimum lokal.

Praktik: gunakan k-means++ dan jalankan beberapa kali (n_init > 1); ambil hasil dengan inertia terkecil.

Memilih K: Elbow dan Silhouette





Elbow: patahan tidak tajam. Inertia turun terus, tidak ada "siku" yang jelas.

Silhouette: puncak di **K = 3** (0,285), sesuai 3 kelas anggur sebenarnya.

Metrik Evaluasi Clustering

Metrik internal (tanpa label) dan eksternal (jika ada label pembanding).

$$s(i) = (b - a) / \max(a, b)$$

a = jarak rata-rata ke cluster sendiri, b = ke cluster terdekat lain

Contoh titik	a	b	s
Cocok di clusternya	2	6	0,67
Di perbatasan	4	4,2	0,05
Kemungkinan salah cluster	5	4	−0,20

s mendekati +1: cluster rapat & terpisah; ≈ 0: tumpang tindih; < 0: kemungkinan salah cluster.

K	Silhouette ↑	Davies-Bouldin ↓	Calinski-Harabasz ↑
2	0,259	1,526	69,5
3	0,285	1,389	70,9
4	0,260	1,797	56,2
5	0,202	1,808	47,0

Konsensus: ketiga metrik internal sepakat memilih **K = 3**. Jika label pembanding ada, tambahkan metrik eksternal seperti **ARI** dan **NMI**. Metrik apa pun hanya penunjang; **interpretasi bisnis** tetap penentu akhir.

C

STUDI KASUS NYATA

MEMILIH K & EVALUASI CLUSTER

Dari Cluster ke Insight: Profil Cluster

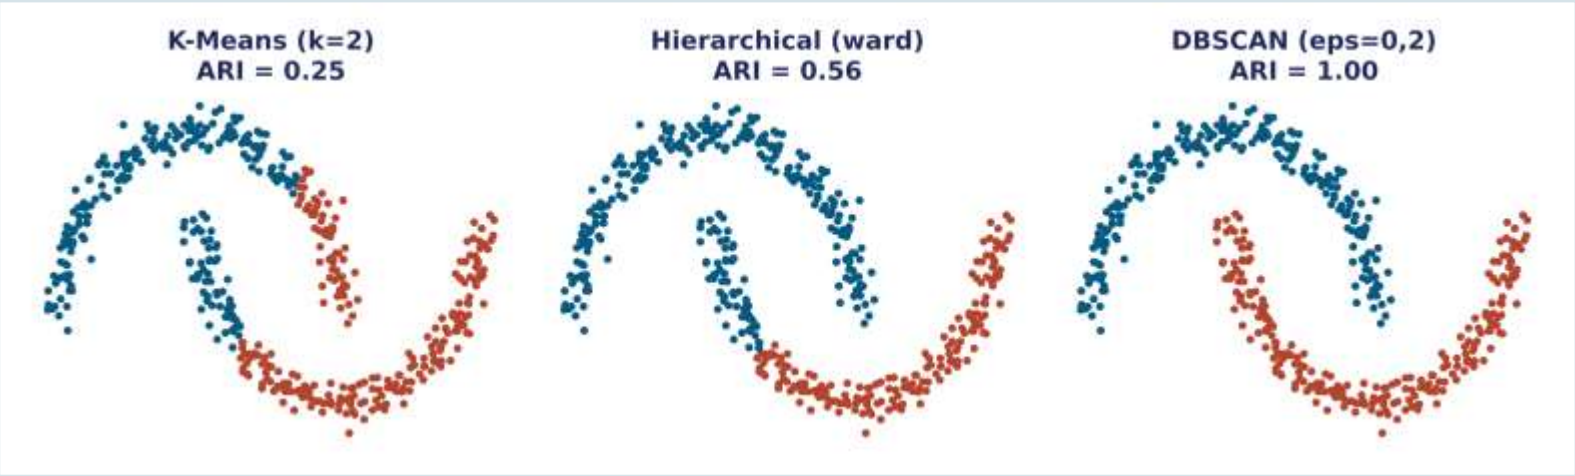
Cluster	Jumlah	alcohol	flavanoids	color_intensity	proline	Interpretasi (pemberian nama oleh analis)
0	65	12.25	2.05	2.97	510	Ringan: flavonoid sedang, warna pucat
1	51	13.13	0.82	7.23	619	Pekat berwarna, flavonoid rendah
2	62	13.68	3.00	5.45	1100	Beralkohol tinggi, flavonoid & proline tinggi

Cara memprofilkan

- Hitung rata-rata fitur per cluster **dalam satuan asli** (bukan terstandarisasi).
- Cari fitur yang paling membedakan.
- Beri nama cluster yang bermakna bagi pengguna.

Validasi eksternal: dibandingkan dengan 3 kultivar anggur sebenarnya (label tidak dipakai saat training), K-Means menempatkan **59 dari 59**, **65 dari 71**, dan **48 dari 48** sampel ke cluster yang dominan sesuai kelas → ARI 0,897.

Ketika K-Means Gagal: Cluster Tidak Bulat



Asumsi K-Means

Cluster berbentuk bola dan berukuran mirip.

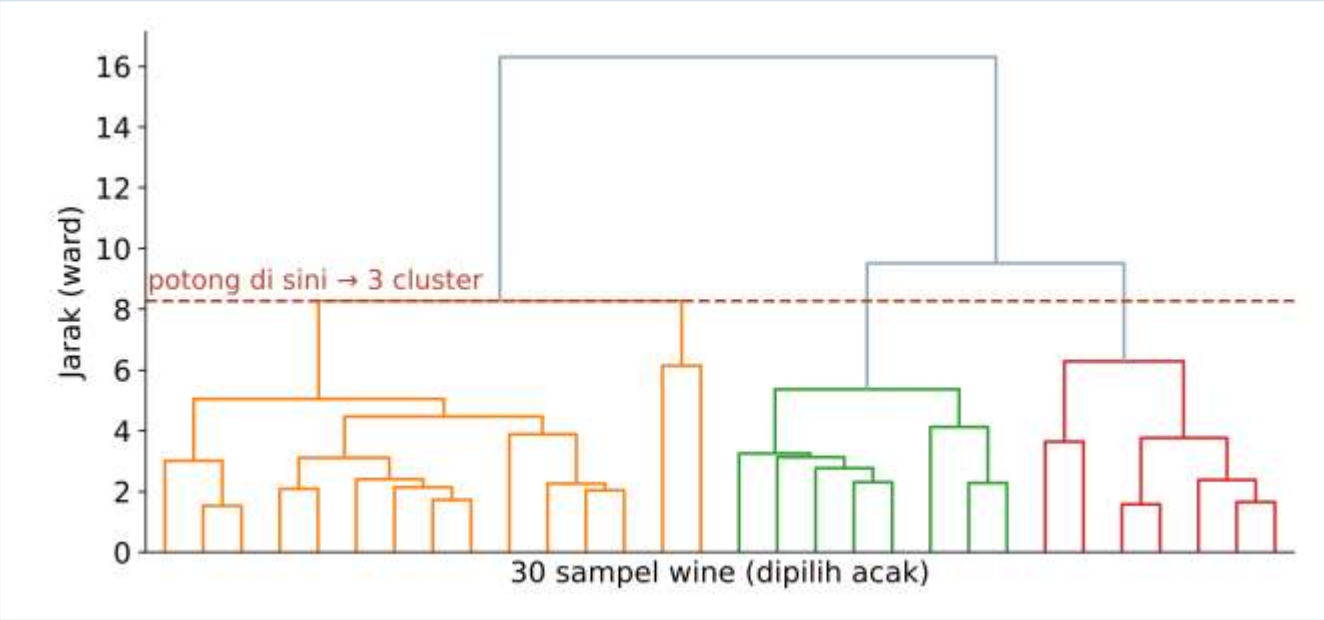
Memotong "bulan sabit" dengan garis lurus, sehingga ARI hanya 0,25.

Algoritma pada data bulan sabit	ARI
K-Means	0.25
Hierarchical (ward)	0.56
Hierarchical (single)	1.00
DBSCAN (eps = 0,2)	1.00

Pelajaran: pilih algoritma sesuai **bentuk** cluster. Algoritma berbasis kerapatan (DBSCAN) dan single-linkage mengikuti bentuk sembarang; K-Means dan ward cenderung menyukai bentuk bulat.

Hierarchical Clustering dan Dendrogram

Membangun pohon penggabungan (bottom-up): tiap titik awalnya satu cluster, lalu pasangan terdekat digabung.



Linkage	Jarak antar cluster	Kecenderungan
single	terdekat antar titik	Bentuk memanjang; rawan chaining
complete	terjauh antar titik	Cluster padat, ukuran sama
average	rata-rata antar titik	Kompromi
ward	kenaikan varians terkecil	Cluster bulat; paling umum

Membaca dendrogram: potong pada tinggi tertentu; lompatan jarak terbesar menandakan jumlah cluster alami.

Kelemahan: kompleksitas ≥ $O(n^2)$ memori, sulit untuk data sangat besar.

DBSCAN: Cluster = Wilayah Padat

Tidak perlu K; titik di wilayah jarang ditandai noise.

Core point — Punya ≥ min_samples tetangga dalam radius eps.

Border point — Tetangga core, tetapi sendiri tidak padat.

Noise — Bukan keduanya; label −1.

- **eps terlalu kecil** → hampir semuanya noise dan cluster terpecah (eps 0,05: 31 cluster).
- **eps terlalu besar** → semua menyatu (eps ≥ 0,5: 1 cluster).

eps	Cluster	Noise	ARI
0.05	31	215	0.03
0.10	2	8	0.97
0.20	2	0	1.00
0.30	2	0	1.00
0.50	1	0	0.00
0.80	1	0	0.00

Data bulan sabit, min_samples = 5

Tips: pilih eps dari grafik k-distance (jarak ke tetangga ke-k, urut menaik).

Kapan Memakai Algoritma yang Mana?

Ringkasan perbandingan algoritma clustering.

	K-Means	Hierarchical	DBSCAN	GMM
Perlu K di awal	Ya	Tidak (potong dendrogram)	Tidak (butuh eps)	Ya
Bentuk cluster	Bulat	Tergantung linkage	Sembarang	Elips
Noise / outlier	Sensitif	Sensitif	Terdeteksi sebagai noise	Sensitif
Skala data besar	Sangat baik	Kurang baik	Baik	Sedang
Hasil	Hard assignment	Hirarki	Hard + noise	Probabilistik (soft)

Aturan praktis: mulai dari **K-Means** (cepat, baseline) setelah standarisasi; gunakan **DBSCAN** bila cluster tidak bulat atau ada noise; **Hierarchical** untuk data kecil yang ingin dieksplorasi; **GMM** bila perlu keanggotaan probabilistik.

UNIVERSITAS
MIKROSKIL

Dimensionality Reduction

Curse of Dimensionality • PCA • t-SNE & UMAP

e

EKSPERIMEN NYATA

CURSE OF DIMENSIONALITY

Mengapa Dimensi Tinggi Bermasalah?

Pada dimensi tinggi, semua titik terasa "sama jauh" sehingga jarak kehilangan makna.

Dimensi d	(max − min) / min jarak	Simpangan baku / rata-rata
2	797,5	0,475
10	7,694	0,191
100	0,732	0,059
1.000	0,174	0,019
10.000	0,052	0,006

500 titik acak seragam di [0,1]^d; seluruh pasangan jarak Euclidean (seed 0).

Baca tabel: pada d = 2 jarak terjauh ≈ 800× terdekat; pada d = 10.000 hanya ≈ 1,05×.

Jarak kehilangan kontras

Jarak terjauh hampir sama dengan jarak terdekat. Metode berbasis jarak (kNN, K-Means, DBSCAN) memburuk.

Data menjadi jarang

Volume ruang tumbuh eksponensial; jumlah sampel yang sama tersebar sangat tipis.

Overfitting & biaya

Fitur banyak, sampel sedikit → model mudah menghafal; waktu dan memori ikut naik.

Dua Cara Mengurangi Dimensi

Seleksi fitur memilih sebagian kolom asli; ekstraksi fitur membentuk kolom baru.

Feature Selection

- Membuang fitur tidak berguna; kolom asli tetap.
- Mudah ditafsirkan.
- Contoh: filter (korelasi, varians), L1/Lasso, feature importance.

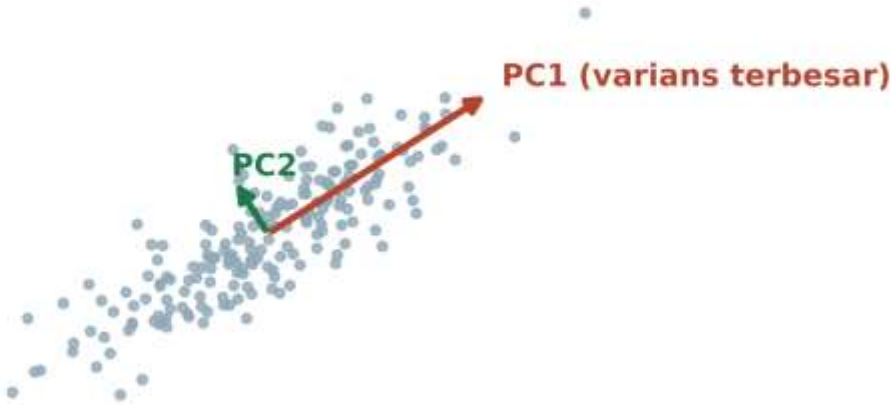
Feature Extraction

- Membuat fitur baru dari kombinasi fitur lama.
- Bisa memadatkan informasi, tapi sulit ditafsirkan.
- Contoh: PCA, LDA, autoencoder, t-SNE, UMAP.

Metode	Jenis	Terawasi?	Kegunaan utama
PCA	Linear	Tidak	Kompresi, pra-pemrosesan, visualisasi
LDA	Linear	Ya (label)	Memisahkan kelas sambil mereduksi
Kernel PCA / Isomap	Non-linear	Tidak	Struktur melengkung (manifold)
t-SNE / UMAP	Non-linear	Tidak	Visualisasi 2D/3D
Autoencoder	Non-linear	Tidak	Representasi laten (deep learning)

PCA: Mencari Arah dengan Varians Terbesar

Memutar sumbu agar sumbu pertama menangkap sebaran data sebanyak mungkin.



> *"PCA is by far the most popular dimensionality reduction algorithm. First it identifies the hyperplane that lies closest to the data, and then it projects the data onto it."*
>
> — A. Géron, Hands-On Machine Learning

Analogi: Bayangan Benda 3D

- Bayangan memetakan benda 3D ke bidang 2D.
- Sudut lampu yang baik memberi bayangan yang **paling informatif** (sebaran terbesar).
- PC1 = sudut terbaik; PC2 = sudut terbaik berikutnya yang **tegak lurus** dengan PC1.

f **PCA: INTUISI & MATEMATIKA**

Langkah dan Contoh Hitungan PCA

Eigen-decomposition dari matriks kovarians.

1	**Standarisasi**	Pusatkan (dan skalakan) tiap fitur.
2	**Matriks kovarians**	$C = X^T X / (n - 1)$
3	**Eigen / SVD**	$Cv = \lambda v$: vektor eigen = arah, nilai eigen = varians.
4	**Urutkan**	Dari λ terbesar ke terkecil.
5	**Proyeksikan**	$Z = X \cdot V_k$ (ambil k vektor pertama).

Contoh: dua fitur berkorelasi

- $C = [[2, 1], [1, 2]]$
- $\lambda_1 = 3, \lambda_2 = 1 \rightarrow$ rasio varians **75% dan 25%**
- $PC1 = (1, 1)/\sqrt{2}$, $PC2 = (1, -1)/\sqrt{2}$

Proyeksi titik (2, 2)

- $z_1 = (2 + 2)/\sqrt{2} = \mathbf{2{,}83}$; $z_2 = (2 - 2)/\sqrt{2} = \mathbf{0}$
- Titik terletak tepat di sumbu PC1, sehingga rekonstruksi dari PC1 saja sempurna.

Rumus: explained variance ratio $= \lambda_i / \Sigma\lambda$

PCA di scikit-learn: Selalu dalam Pipeline

Fit hanya pada data latih, di dalam fold CV.

Notebook Pertemuan 5 – PCA + klasifikasi

```
pipe = Pipeline([
    ("scaler", StandardScaler()),
    ("pca",    PCA(n_components=0.95)),  # simpan 95% varians
    ("clf",    LogisticRegression(max_iter=2000)),
])
scores = cross_val_score(pipe, X, y, cv=5)

pipe.fit(X_train, y_train)
pca = pipe.named_steps["pca"]
print(pca.n_components_)
print(pca.explained_variance_ratio_.cumsum())
```

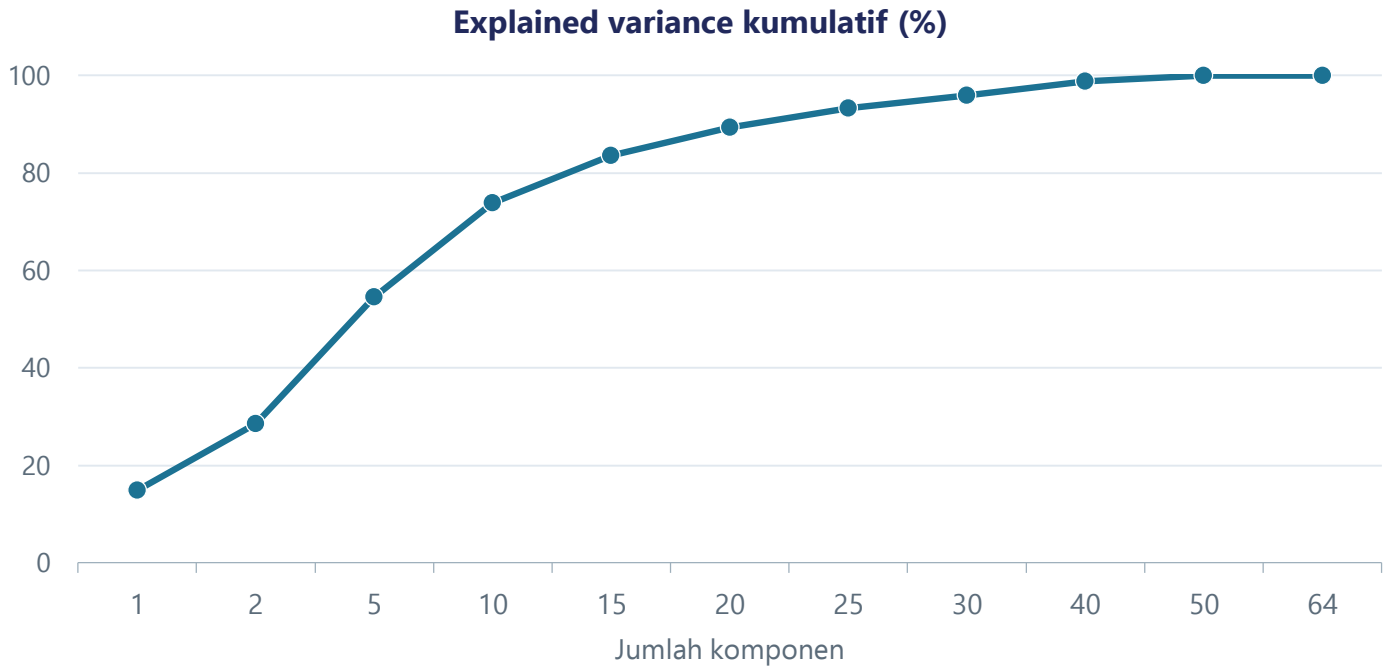
Aturan penting

- **Skalakan dulu** bila satuan fitur berbeda; PCA mengejar varians, sehingga fitur berskala besar mendominasi.
- `n_components` boleh pecahan (0,95) = target varians.
- `fit` pada train saja, sama seperti scaler.

Harga yang dibayar: komponen adalah campuran semua fitur sehingga **interpretabilitas turun**; PCA juga hanya menangkap struktur **linear**.

Digits: Berapa Komponen yang Cukup?

1.797 gambar 8×8 piksel (64 fitur), angka 0–9.



13
komponen untuk 80% varians

21
komponen untuk 90% varians

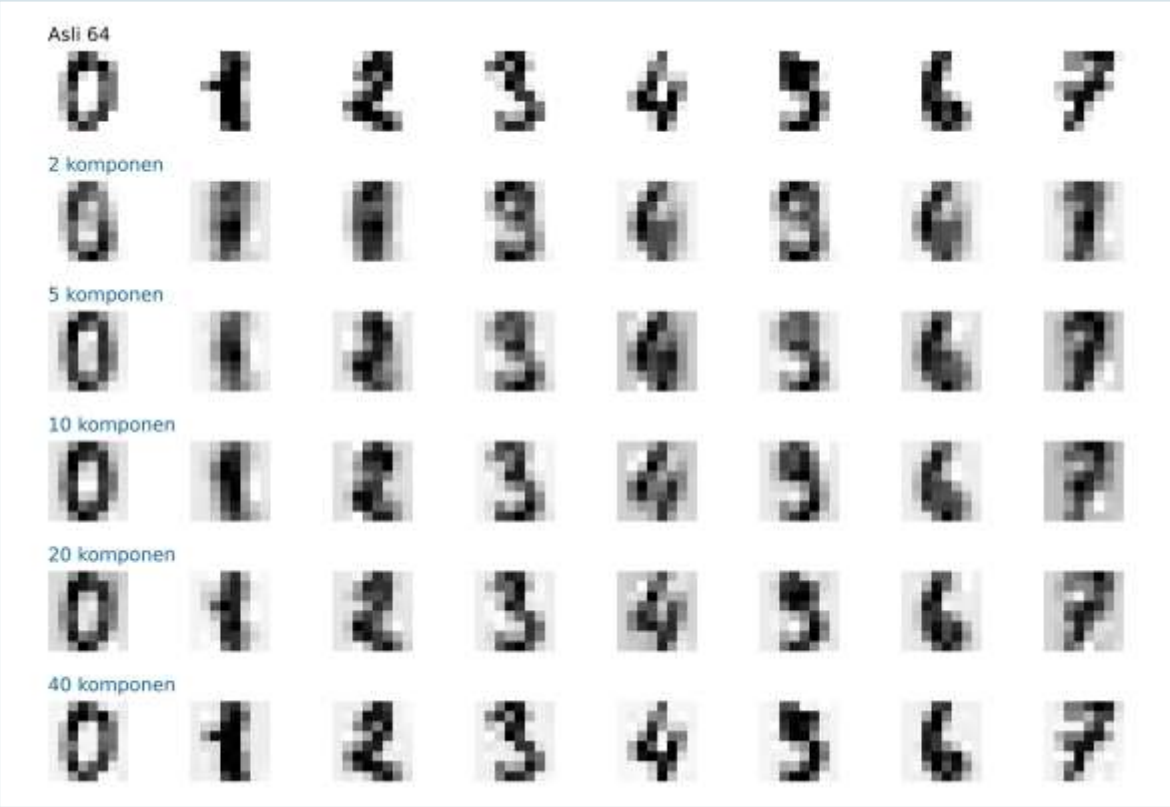
29
komponen untuk 95% varians

41
komponen untuk 99% varians

Hasil: 64 fitur → **21 komponen** sudah menyimpan 90% varians; PC1 dan PC2 hanya 14,9% dan 13,6%, jadi plot 2D membuang banyak informasi.

Rekonstruksi: Seberapa Mirip dengan Aslinya?

Gambar dikompres ke k komponen lalu dikembalikan ke 64 piksel.

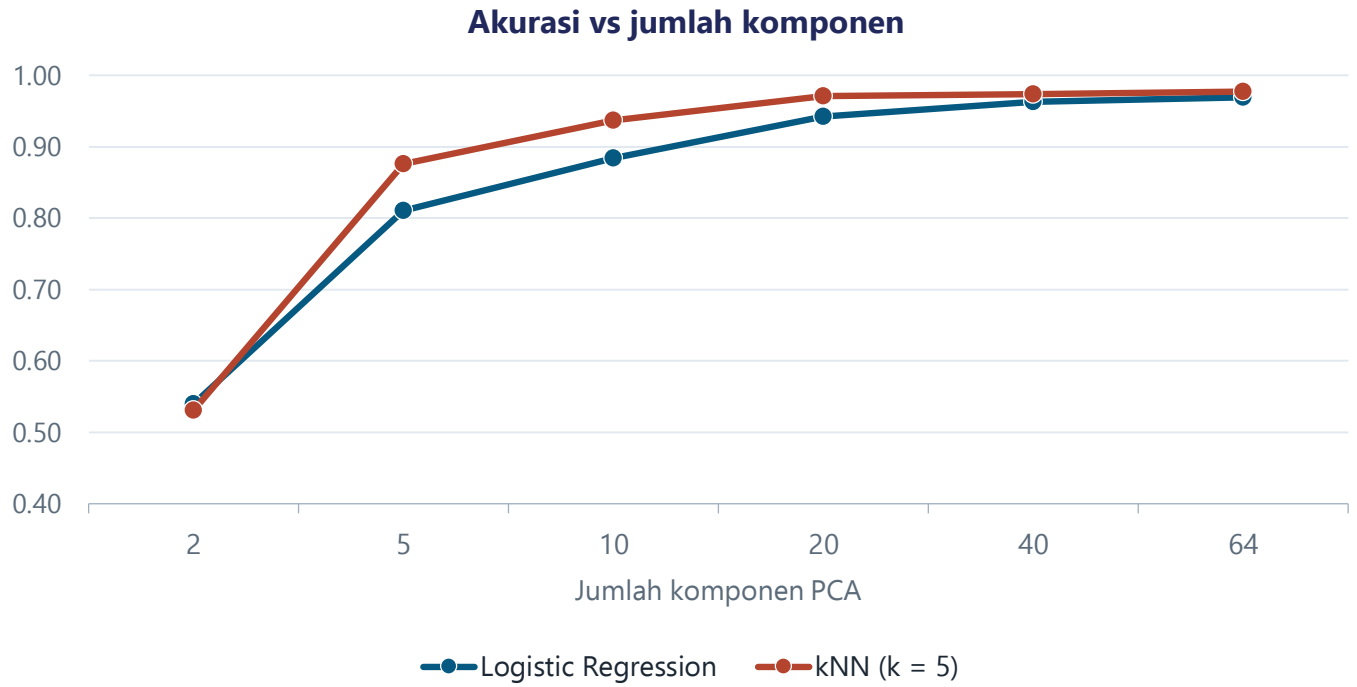


Komponen k	MSE rekonstruksi
2	13,42
5	8,54
10	4,91
20	1,98
40	0,22

Makna: PCA = **kompresi dengan kehilangan**. Menyimpan 20 dari 64 angka per gambar sudah membuat digit terbaca; kesalahan rekonstruksi turun cepat lalu melambat.

Apakah PCA Meningkatkan Klasifikasi?

Akurasi 5-fold stratified CV; PCA berada di dalam Pipeline.



Temuan jujur

- kNN: **0,977** → **0,971** dengan hanya 20 dari 64 dimensi (−0,6 poin).
- Logistic Regression: tanpa PCA terbaik (0,969); dengan 20 komponen 0,942.
- GridSearchCV atas n_components memilih **64**, yaitu tidak mereduksi.

Pelajaran: PCA tidak otomatis menaikkan akurasi. Gunakan saat perlu **kompresi, kecepatan, atau mengurangi noise**, lalu ukur dengan CV.

PCA + K-Means pada Digits

K-Means (k = 10) tanpa label; ARI dihitung terhadap digit sebenarnya.

Input K-Means	ARI	NMI	Silhouette
64 piksel mentah	0,468	0,626	0,147
PCA 20 komponen	0,549	0,682	0,198
PCA 10 komponen	0,485	0,631	0,274
PCA 2 komponen	0,326	0,465	0,377

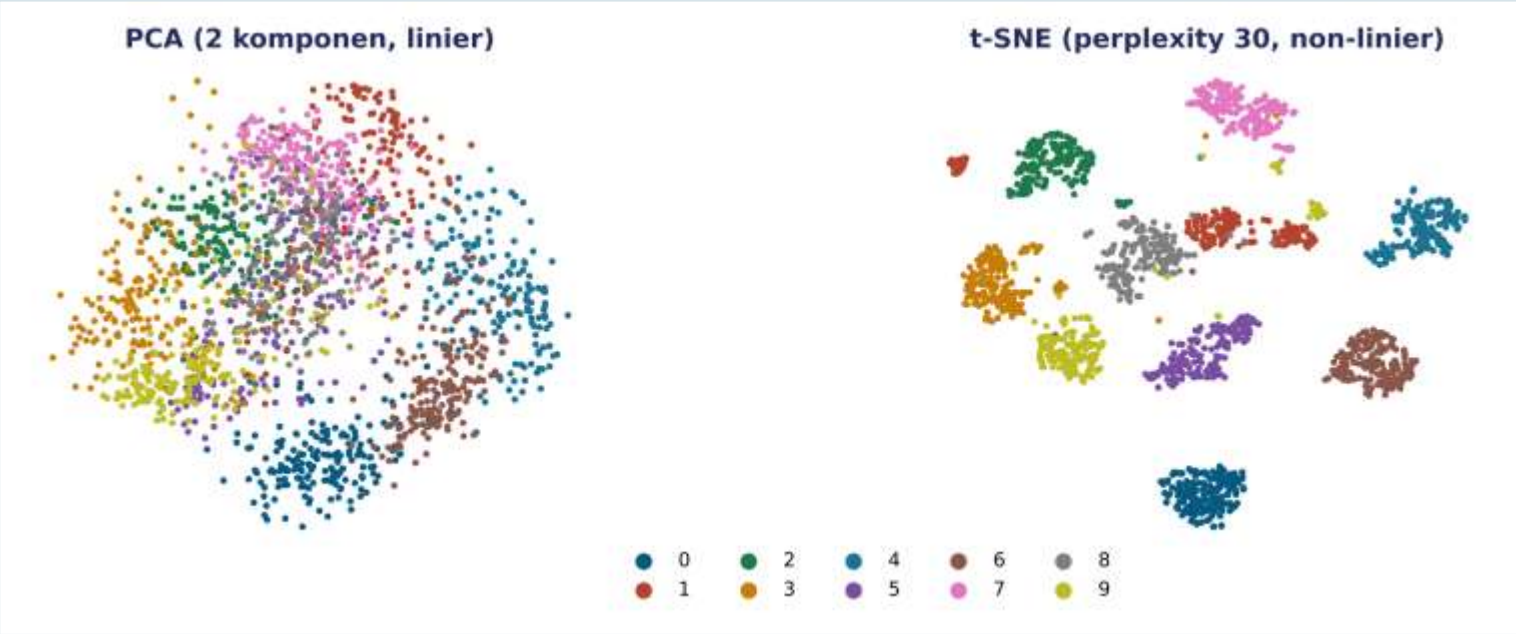
Mengapa PCA 20 membaik?

Dimensi sisa berisi banyak **noise**. Membuangnya membuat jarak Euclidean lebih informatif bagi K-Means.

Awas silhouette: silhouette **naik** terus saat dimensi turun (0,147 → 0,377), padahal ARI justru turun pada 2 komponen (0,326). Silhouette tidak dapat dibandingkan antar ruang fitur berbeda. Gunakan ARI/NMI bila label tersedia, dan pakai silhouette hanya untuk membandingkan K pada **ruang yang sama**.

PCA vs t-SNE untuk Visualisasi

Digits diproyeksikan ke 2D; warna = digit sebenarnya.



Yang terlihat

- **PCA 2D:** kelas bertumpuk karena hanya ±28% varians tertangkap.
- **t-SNE:** kelompok digit terpisah jelas karena mempertahankan **tetangga terdekat**.

Tetapi: t-SNE hanya cocok untuk **melihat** data. Jangan memakainya sebagai fitur untuk model, dan jangan menafsirkan jarak atau ukuran cluster pada plotnya.

PCA, t-SNE, dan UMAP: Perbandingan dan Jebakan

Tiga alat berbeda untuk tujuan berbeda.

	PCA	t-SNE	UMAP
Jenis	Linear	Non-linear	Non-linear
Data baru (transform)	Ya	Tidak (sklearn)	Ya
Struktur global	Terjaga	Sering rusak	Lebih baik dari t-SNE
Kecepatan	Sangat cepat	Lambat	Lebih cepat dari t-SNE
Hyperparameter	n_components	perplexity, iterasi	n_neighbors, min_dist
Dipakai untuk	Pra-pemrosesan, kompresi	Visualisasi	Visualisasi, kadang fitur

Jebakan membaca plot t-SNE / UMAP

- Ukuran cluster dan jarak antar cluster **tidak bermakna**.
- Hasil berubah menurut perplexity dan seed; coba beberapa nilai.
- Pola bisa muncul dari noise. Jangan menyimpulkan jumlah cluster hanya dari plot.

Memilih Jumlah Komponen

Tidak ada angka ajaib; sesuaikan dengan tujuan.

1 Ambang varians

Ambil k terkecil sehingga varians kumulatif ≥ 90–95%.

Digits: 21 (90%) atau 29 (95%).

2 Scree plot

Cari "siku" pada plot varians per komponen.

Sering tidak tajam; pakai sebagai petunjuk.

3 Validasi tugas hilir

Perlakukan n_components sebagai hyperparameter dalam GridSearchCV.

Paling objektif untuk model prediktif.

Visualisasi vs modeling: untuk **plot** pakai 2 atau 3 komponen (terima bahwa informasi hilang). Untuk **model** pilih k dari ambang varians atau CV; di dalam Pipeline.

Checklist Unsupervised Learning di Project

Gunakan sebagai rubrik mandiri untuk laporan.

1 Standarisasi

Skalakan fitur sebelum K-Means, DBSCAN, PCA.

2 Pilih K bijak

Gabungkan elbow, silhouette, DB, CH, dan logika bisnis.

3 Sesuaikan bentuk

Cluster tidak bulat? Coba DBSCAN atau hierarchical.

4 Profilkan cluster

Rata-rata fitur dalam satuan asli, lalu beri nama.

5 Hindari leakage

Scaler dan PCA di-fit di train saja (Pipeline).

6 Laporkan jujur

Sertakan seed, ukuran cluster, dan batas interpretasi.

? CEK PEMAHAMAN

Pertanyaan Diskusi

Jawab singkat, lalu diskusikan dengan teman sebangku (3 menit).

1. Mengapa K-Means pada data Wine tanpa scaling menghasilkan ARI jauh lebih rendah (0,37) daripada setelah scaling (0,90)?

2. Elbow plot tidak menunjukkan siku yang jelas. Metrik apa lagi yang dapat dipakai untuk memilih K, dan apa batasannya?

3. Data berbentuk dua bulan sabit. Algoritma mana yang cocok, dan mengapa K-Means gagal?

4. PCA 2 komponen hanya menyimpan 28% varians digits. Apa konsekuensinya bila plot 2D dipakai untuk menyimpulkan jumlah cluster?

5. Mengapa StandardScaler dan PCA harus di-fit hanya pada data latih, dan bagaimana Pipeline membantu?

RINGKASAN PERTEMUAN 5

- Unsupervised → belajar dari x saja; evaluasi dan interpretasi menjadi tugas analis
- K-Means → cepat dan sederhana, tetapi butuh scaling, K, dan cluster berbentuk bulat
- Memilih K → Elbow, Silhouette, DB, CH, serta ARI/NMI bila ada label; jangan bandingkan silhouette lintas ruang
- Hierarchical & DBSCAN → untuk bentuk sembarang, noise, atau eksplorasi tanpa K
- PCA → proyeksi ke arah varians terbesar; dalam Pipeline, setelah scaling, pilih k lewat varians atau CV
- t-SNE/UMAP → untuk visualisasi, bukan fitur dan bukan ukuran jarak

Terima Kasih - Q & A

PROJECT MILESTONE

Pertemuan 5: Eksplorasi Struktur Data (Clustering & Reduksi Dimensi)

1	**Siapkan fitur**	Pilih fitur numerik dan standarisasi di dalam Pipeline.
2	**Lakukan clustering**	Jalankan K-Means; pilih K dengan Elbow dan Silhouette (dan DB/CH). Bandingkan dengan satu algoritma lain bila relevan.
3	**Profilkan cluster**	Hitung rata-rata fitur per cluster, beri nama, dan jelaskan maknanya bagi masalah project.
4	**Terapkan PCA**	Buat scree plot / explained variance, tentukan jumlah komponen, dan buat visualisasi 2D.
5	**Uji manfaat reduksi**	Bandingkan model atau clustering dengan dan tanpa PCA memakai CV; laporkan hasil jujur.

OUTPUT PROJECT PERTEMUAN 5

A. Persiapan Data

- Fitur yang dipakai;
- Metode scaling;
- Bukti tanpa leakage (Pipeline).

B. Clustering

- Algoritma dan alasan pemilihannya;
- Grafik Elbow / Silhouette;
- Jumlah K terpilih dan ukuran cluster.

C. Profil & Interpretasi

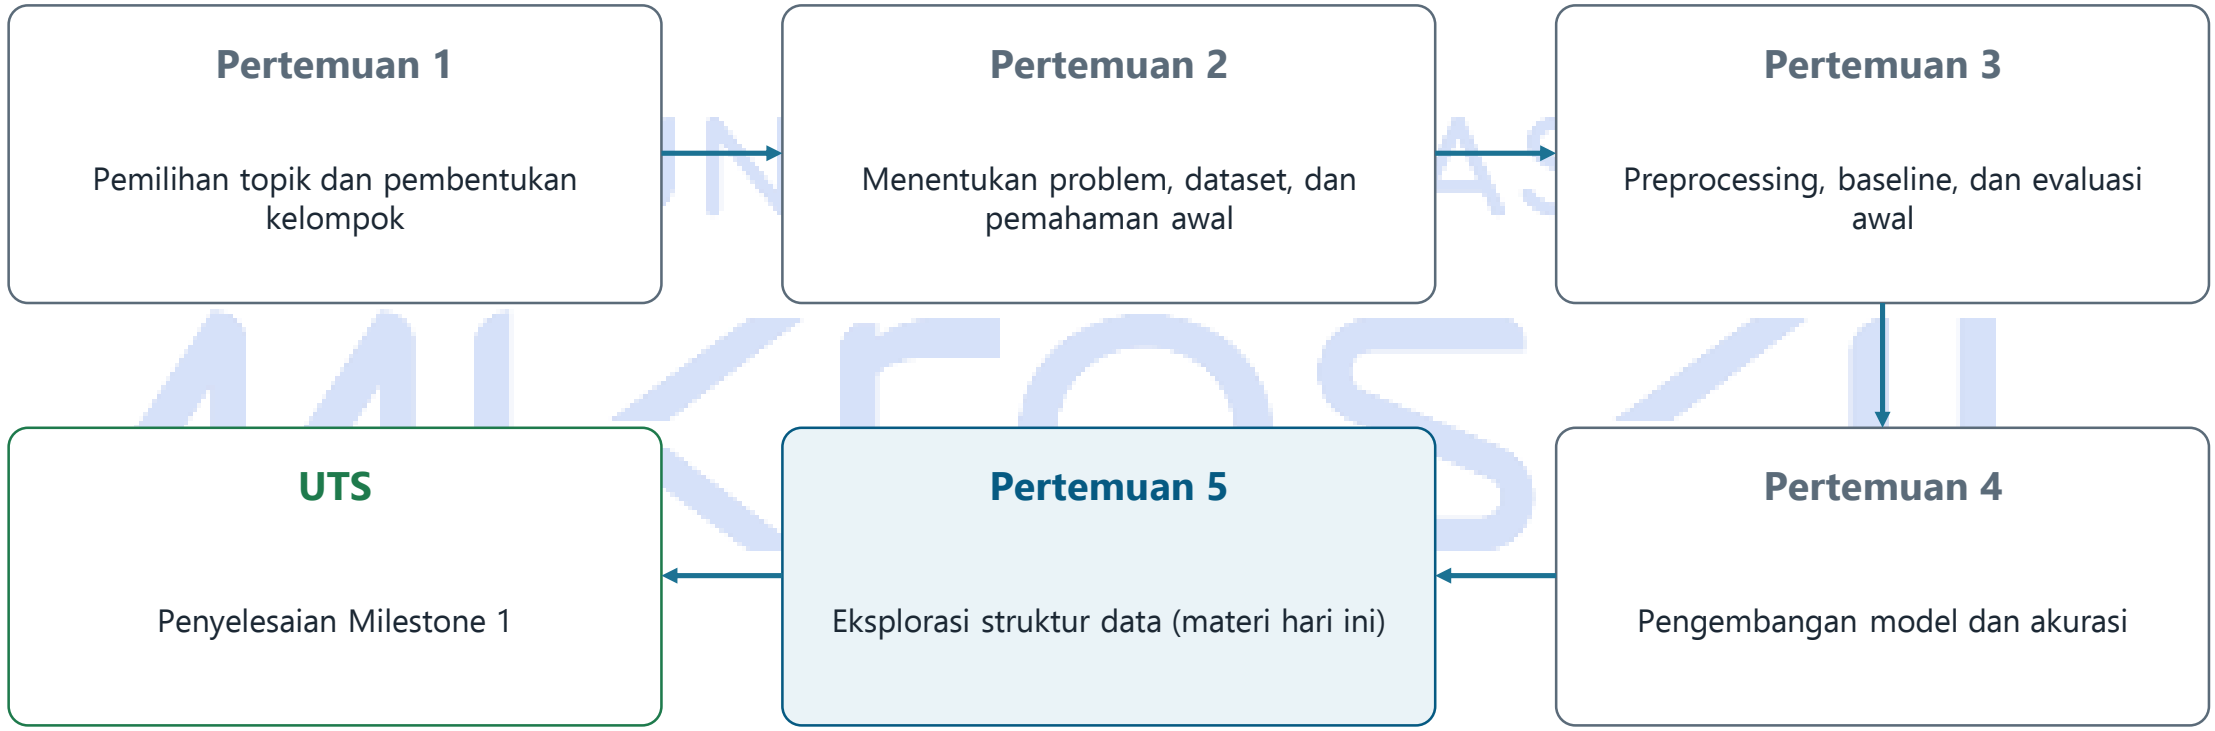
- Tabel rata-rata fitur per cluster;
- Nama dan makna tiap cluster;
- Batasan interpretasi.

D. Reduksi Dimensi

- Scree plot dan jumlah komponen;
- Plot 2D (PCA atau t-SNE);
- Perbandingan dengan/tanpa PCA.

HUBUNGAN DENGAN UTS

Project Milestone



Pada UTS, proyek harus sudah menunjukkan bahwa proyek benar-benar berjalan, bukan hanya proposal.

i REFERENSI

Bacaan Lanjutan

Topik	Sumber
Buku utama	A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow (bab Unsupervised Learning; bab Dimensionality Reduction)
K-Means	S. Lloyd (1982) Least squares quantization in PCM; Arthur & Vassilvitskii (2007) k-means++: The Advantages of Careful Seeding
DBSCAN	Ester, Kriegel, Sander, Xu (1996) A Density-Based Algorithm for Discovering Clusters, KDD
Evaluasi cluster	P. Rousseeuw (1987) Silhouettes: a graphical aid to the interpretation and validation of cluster analysis
PCA	K. Pearson (1901); H. Hotelling (1933); Jolliffe, Principal Component Analysis (2002)
t-SNE & UMAP	van der Maaten & Hinton (2008) Visualizing Data using t-SNE; McInnes, Healy, Melville (2018) UMAP; Wattenberg et al. (2016) How to Use t-SNE Effectively
Dokumentasi	scikit-learn user guide: Clustering; Decomposing signals in components (PCA)